

Análisis de comportamiento de usuarios en ecommerce

Trabajo Práctico Final - Minería de Datos

Camila Durand

Mateo Troncoso

2026-06-26

Table of contents

1	Introducción	2
2	Objetivos	2
2.1	Objetivo general	2
2.2	Objetivos específicos	2
2.3	Origen y características	3
3	Exploración y preparación de datos	3
3.1	Limpieza Inicial	3
3.2	Estadísticas descriptivas	3
4	Análisis gráfico	4
4.1	Distribución de clicks por sesión	4
4.2	Categorías más vistas	4
4.3	Productos más vistos	5
4.4	Análisis de precio	6
4.5	Relación entre la navegación y diversidad de productos	7
4.6	Mapa de tráfico global	8
4.7	Comparativa de categoría de preda por país	9
4.8	Comparativa de categoría de prenda por localización	10
5	Evolución temporal de los clics	11
6	Conjunto de itemsets frecuentes	12
6.0.1	Metodología	12
6.0.2	Resultados - nivel general (solo Categoría)	12
6.0.3	Resultados - nivel específico (Categoría + Modelo)	13
6.0.4	Resultados - nivel moda (Categoría + Color)	13
6.0.5	Colores Más Frecuentes en Combinaciones	14
6.0.6	Cuadro comparativo: Apriori vs ECLAT	14

7	Análisis de los patrones secuenciales	15
7.1	Top 15 secuencias frecuentes de navegación	15
7.2	Top 15 secuencias frecuentes de modelos	15
7.3	Reglas secuenciales con mayor confianza	16
7.4	Top 10 Reglas de Asociación: Polonia (Blusas)	17
7.5	Top 10 Reglas de Asociación: República Checa (Blusas)	18
8	Conclusiones:	18

1 Introducción

En la actualidad, las plataformas de comercio electrónico generan grandes volúmenes de datos relacionados con la navegación e interacción de los usuarios. El análisis de estos datos permite comprender patrones de comportamiento, preferencias de consumo y recorridos de exploración dentro de una tienda online.

La minería de datos aplicada al comercio electrónico permite identificar relaciones entre productos, descubrir patrones frecuentes de navegación y generar conocimiento útil para estrategias de marketing, sistemas de recomendación y técnicas de cross-selling.

En el presente trabajo se analizará un conjunto de datos perteneciente a una tienda online de ropa correspondiente al año 2008. A partir de técnicas de análisis exploratorio, visualización de datos, minería de itemsets frecuentes, reglas de asociación y análisis secuencial, se buscará comprender cómo interactúan los usuarios con los productos y categorías del sitio web.

Además, se estudiarán diferencias de comportamiento entre distintos países y se analizará la influencia de variables como ubicación visual, categoría y rango de precio en la exploración de productos.

2 Objetivos

2.1 Objetivo general

Descubrir patrones de comportamiento de navegación dentro de una tienda online de ropa con el fin de generar conocimiento útil para sistemas de recomendación, estrategias de cross-selling y análisis de comportamiento de usuarios.

2.2 Objetivos específicos

1. Identificar productos que suelen visualizarse conjuntamente
2. Detectar combinaciones de productos relevantes para campañas de cross-selling
3. Comparar hábitos de navegación entre países
4. Encontrar secuencias típicas de exploración de productos
5. Generar conocimiento para sistemas de recomendación

2.3 Origen y características

El dataset proviene del repositorio UCI y contiene información de navegación de una tienda online polaca de ropa para embarazadas durante 5 meses del año 2008.

Característica	Valor
Período	Abril - Agosto 2008
Registros totales	161523
Sesiones únicas	23096
Productos distintos	217
Países representados	42

3 Exploración y preparación de datos

3.1 Limpieza Inicial

Decisiones de limpieza:

- Se eliminó la variable `year` porque todos los registros son de 2008.
- Se filtraron los códigos de dominio de red 43 al 47 de la variable `country` ya que no representan a ningún país.
- Se transformaron variables numéricas a factores a etiquetas descriptivas.
- La etiqueta del id de session la pasamos de tipo numérico a factor para implementar de manera efectiva los algoritmos correspondientes.

3.2 Estadísticas descriptivas

Estadístico	Clicks por sesión	Precio (USD)
Mínimo	1	18
Mediana	6	43
Media	9.9	43.8
Máximo	195	82

Observación clave: La distribución de clicks por sesión está fuertemente sesgada a la derecha (media 9.9, mediana 6), indicando que la mayoría de los usuarios realizan navegaciones cortas, mientras que una minoría explora extensivamente.

4 Análisis gráfico


4.1 Distribución de clicks por sesión

El histograma permite analizar la intensidad de navegación de los usuarios dentro del ecommerce, considerando la cantidad de clicks realizados en cada sesión.

Se observa una distribución fuertemente asimétrica hacia la derecha, donde la mayoría de las sesiones presentan pocos clicks, mientras que un número reducido de usuarios realiza exploraciones mucho más extensas.


En particular:

- aproximadamente el 75% de las sesiones registran entre 1 y 12 clicks, lo que coincide con lo hallado en el análisis estadístico.
- A medida que aumenta la cantidad de clicks, la frecuencia de sesiones disminuye.




4.2 Categorías más vistas

La gráfica muestra que la categoría **pantalones** concentra la mayor cantidad de interacciones, alcanzando aproximadamente 48.000 visualizaciones. En segundo lugar aparecen las categorías **oferta**, **blusas** y **faldas**, con niveles de interacción relativamente similares.




4.3 Productos más vistos

La gráfica muestra los quince productos con mayor cantidad de visualizaciones. El producto **B4** lidera claramente el ranking, seguido por **A2**, **A11** y **P1**.



4.4 Análisis de precio

El análisis de los diagramas de caja indica que los productos con un precio superior al promedio presentan un volumen de clics ligeramente mayor y una dispersión más amplia en sus interacciones. Por el contrario, los artículos más económicos muestran interacciones más bajas y concentradas, aunque ambos grupos registran valores atípicos significativos que logran superar los 2500 clics.




4.5 Relación entre la navegación y diversidad de productos

Se observa una relación positiva entre la cantidad de clicks realizados en una sesión y la cantidad de productos distintos explorados. A medida que aumenta la cantidad de clicks, los usuarios tienden a visualizar una mayor diversidad de productos. Segmentamos por cantidad de clicks ya que al querer graficarlos en un mismo gráfico dificultaba la visualización de la información.

Exploración de productos por sesión

Relación entre navegación y diversidad de productos




4.6 Mapa de tráfico global

La mayor parte del tráfico se concentra en Europa, con Polonia, República Checa y Alemania como los principales países de origen. Polonia es el mercado principal con 17,000 sesiones, mientras que el resto de países suele tener alrededor de 2500 sesiones.

Distribución global de sesiones de usuario

Intensidad de color indica mayor actividad por país




Nota: Países en gris claro sin datos disponibles

4.7 Comparativa de categoría de preda por país

Filtramos para ver los 20 países con mayor cantidad de clicks para facilitar la visualización del gráfico.

Polonia presentó niveles de interacción considerablemente superiores al resto de los mercados, lo que lo posiciona como el principal origen de navegación del ecommerce. Además, las categorías pantalones y ofertas mostraron mayor interacción en dicho país, contando con más de 30.000 clicks.




4.8 Comparativa de categoría de prenda por localización

El análisis de las interacciones revela que la arquitectura espacial de la interfaz condiciona el tráfico de usuarios, concentrando la atención en el cuadrante superior izquierdo. Donde la categoría pantalones alcanza un pico de 10855 clicks, y perdiendo retención progresivamente hasta el extremo opuesto, con un mínimo de 3.423 clicks para faldas, lo que demuestra empíricamente la necesidad estratégica de reservar los bloques superiores de la pantalla para el inventario de mayor prioridad comercial.

Interacción entre ubicación y categoría


Distribución de clics según posición en pantalla



5 Evolución temporal de los clics

La gráfica presenta la evolución de la cantidad total de clics entre abril y agosto de 2008. Se observa un volumen elevado de actividad durante abril, seguido por una disminución gradual en los meses posteriores. Julio muestra una leve recuperación respecto de junio, mientras que agosto registra una caída pronunciada.

Este comportamiento indica que la intensidad de navegación no fue uniforme a lo largo del período analizado, aunque los patrones de exploración identificados mediante minería secuencial se mantuvieron consistentes independientemente del volumen total de tráfico.



6 Conjunto de itemsets frecuentes

6.0.1 Metodología

Para identificar productos que suelen visualizarse conjuntamente, se aplicaron los algoritmos **Apriori** y **ECLAT** con un soporte mínimo del 2% y longitud mínima de 2 ítems. Se analizaron tres niveles de granularidad:

- **Nivel general:** Solo categorías principales, 4 ítems. Objetivo: Patrones generales de navegación.
- **Nivel específico:** Categoría + modelo de ropa, 218 ítems. Objetivo: Cross-selling preciso.
- **Nivel moda:** Categoría + color, 43 ítems. Objetivo: Tendencias de color.

6.0.2 Resultados - nivel general (solo Categoría)

Los usuarios no navegan categorías aisladas, exploran conjuntos compatibles de prendas. Existe la posibilidad de que los usuarios exploren outfits completos.

N°	Itemset	Soporte (%)	Conteo
1	{blusas, pantalones}	24.82	5,732
2	{faldas, pantalones}	22.67	5,235
3	{blusas, faldas}	20.96	4,841
4	{oferta, pantalones}	20.65	4,769
5	{blusas, oferta}	19.23	4,442
6	{faldas, oferta}	17.77	4,104
7	{blusas, faldas, pantalones}	13.92	3,215
8	{blusas, oferta, pantalones}	11.90	2,749
9	{faldas, oferta, pantalones}	10.85	2,506
10	{blusas, faldas, oferta}	10.64	2,458

6.0.3 Resultados - nivel específico (Categoría + Modelo)

En este caso estudiamos productos en concreto, existen grupos de productos específicos que se exploran conjuntamente de manera recurrente. Los usuarios observan activamente productos dentro de una misma categoría antes de continuar navegando.

N°	Itemset	Soporte (%)	Conteo
1	{faldas_B10, faldas_B13}	3.71	856
2	{pantalones_A2, pantalones_A5}	3.67	847
3	{pantalones_A1, pantalones_A2}	3.64	841
4	{pantalones_A11, pantalones_A2}	3.49	805
5	{pantalones_A2, pantalones_A3}	3.40	786
6	{pantalones_A10, pantalones_A2}	2.96	684
7	{pantalones_A10, pantalones_A9}	2.89	667
8	{pantalones_A3, pantalones_A5}	2.88	666
9	{pantalones_A1, pantalones_A11}	2.75	636
10	{pantalones_A2, pantalones_A7}	2.74	632

6.0.4 Resultados - nivel moda (Categoría + Color)

Los usuarios comparan variantes visuales, mismo producto diferentes colores, del mismo tipo de producto, los colores más buscados son negro, azul y marrón. Además, **las blusas blancas** se asocian con pantalones azules con un soporte del 8.0%.

N°	Itemset	Soporte (%)	Conteo
1	{pantalones_azul, pantalones_negro}	11.52	2,661
2	{oferta_marron, oferta_negro}	9.91	2,289
3	{faldas_negro, faldas_rojo}	9.41	2,173
4	{pantalones_azul, pantalones_beige}	9.40	2,170
5	{blusas_blanco, pantalones_azul}	8.01	1,850
6	{oferta_marron, pantalones_azul}	7.85	1,813
7	{blusas_blanco, blusas_gris}	7.76	1,792

N°	Itemset	Soporte (%)	Conteo
8	{blusas_gris, pantalones_azul}	7.55	1,744
9	{oferta_negro, pantalones_azul}	7.32	1,691
10	{faldas_negro, pantalones_azul}	7.29	1,684

6.0.5 Colores Más Frecuentes en Combinaciones

El color negro es el más frecuente con 122 apariciones, seguido por azul con 76 y marrón con 44. Además, los colores neutros, negro, azul, beige, gris, predominan sobre tonos vibrantes, rojo, rosa, violeta.

N°	Color	Frecuencia (n)
1	Negro	122
2	Azul	76
3	Marrón	44
4	Verde	36
5	Beige	33
6	Violeta	30
7	Rojo	28
8	Multicolor	27
9	Gris	25
10	Blanco	17

6.0.6 Cuadro comparativo: Apriori vs ECLAT

Nivel de análisis	Algoritmo	Itemsets encontrados	Tiempo de ejecución (seg)	Diferencia
General	Apriori	11	0.03	–
	ECLAT	11	0.02	ECLAT fue el más rápido
Específico	Apriori	66	0.03	–
	ECLAT	66	0.06	Apriori fue el más rápido
Moda	Apriori	470	0.03	–
	ECLAT	470	0.04	ECLAT fue más más lento

7 Análisis de los patrones secuenciales

7.1 Top 15 secuencias frecuentes de navegación

Las secuencias más frecuentes muestran un comportamiento de **exploración repetitiva**, los usuarios tienden a **mirar productos similares** :

- $\langle \{\text{pantalones}\}, \{\text{pantalones}\} \rangle$ (37.4%): Usuarios que ven un pantalón, ven otro pantalón después
- $\langle \{\text{pantalones}\}, \{\text{pantalones}\}, \{\text{pantalones}\} \rangle$ (26.3%): Comparación de múltiples pantalones
- Este patrón se repite para faldas (31.7%) y blusas (29.1%)

Nº	Secuencia	Soporte (%)
1	$\langle \{\text{pantalones}\} \rangle$	54.45
2	$\langle \{\text{faldas}\} \rangle$	48.06
3	$\langle \{\text{blusas}\} \rangle$	44.61
4	$\langle \{\text{oferta}\} \rangle$	39.02
5	$\langle \{\text{pantalones}\}, \{\text{pantalones}\} \rangle$	37.43
6	$\langle \{\text{faldas}\}, \{\text{faldas}\} \rangle$	31.67
7	$\langle \{\text{blusas}\}, \{\text{blusas}\} \rangle$	29.11
8	$\langle \{\text{pantalones}\}, \{\text{pantalones}\}, \{\text{pantalones}\} \rangle$	26.34
9	$\langle \{\text{oferta}\}, \{\text{oferta}\} \rangle$	26.18
10	$\langle \{\text{faldas}\}, \{\text{faldas}\}, \{\text{faldas}\} \rangle$	21.77
11	$\langle \{\text{blusas}\}, \{\text{blusas}\}, \{\text{blusas}\} \rangle$	20.31
12	$\langle \{\text{pantalones}\}, \{\text{pantalones}\}, \{\text{pantalones}\}, \{\text{pantalones}\} \rangle$	19.05
13	$\langle \{\text{oferta}\}, \{\text{oferta}\}, \{\text{oferta}\} \rangle$	18.67
14	$\langle \{\text{pantalones}\}, \{\text{blusas}\} \rangle$	18.36
15	$\langle \{\text{pantalones}\}, \{\text{faldas}\} \rangle$	15.46

7.2 Top 15 secuencias frecuentes de modelos

A diferencia de las categorías, las secuencias más frecuentes de modelos corresponden únicamente a secuencias de longitud uno.

Los modelos más visitados fueron:

- **B4 (13,56%)**: modelo con mayor presencia en las sesiones de navegación.
- **A2 (10,63%)** y **A11 (10,37%)**: productos que también concentran una parte importante de las visualizaciones.
- Los modelos **B10**, **P1**, **A15** y **A4** presentan soportes cercanos al 10%, mostrando un interés relativamente homogéneo entre varios productos destacados.

Este comportamiento sugiere que los usuarios exploran una variedad de modelos dentro de una misma categoría, sin seguir patrones de navegación repetitivos entre productos específicos.

N°	Secuencia	Soporte (%)
1	<{B4}>	13.56
2	<{A2}>	10.63
3	<{A11}>	10.37
4	<{B10}>	10.25
5	<{P1}>	9.64
6	<{A15}>	9.45
7	<{A4}>	9.32
8	<{A1}>	8.81
9	<{A5}>	8.08
10	<{B13}>	7.59
11	<{A10}>	7.52
12	<{A12}>	6.99
13	<{B24}>	6.93
14	<{C5}>	6.85
15	<{A3}>	6.80

7.3 Reglas secuenciales con mayor confianza

Se realizó una investigación extra para observar las reglas secuenciales con mayor confianza en la cual obtuvimos lo siguiente:

1. **La categoría “oferta” actúa como destino final:** Múltiples reglas muestran que después de explorar varias categorías con blusas, pantalones ofaldas; los usuarios terminan en la sección de ofertas.
2. **Confianzas muy altas:** Si un usuario ha visto 3 o más productos de una categoría, la probabilidad de que luego vea la sección de ofertas es muy alta.
3. **Lift mayor a 1:** La asociación entre exploración intensiva y visita a ofertas es estadísticamente significativa.

N°	Regla (LHS → RHS)	Soporte (%)	Confianza (%)	Lift
1	<{blusas},{blusas},{blusas},{oferta}> → <{oferta}>	5.55	77.84	2.00
2	<{pantalones},{fal- das},{blusas},{oferta}> → <{oferta}>	2.14	77.43	1.98
3	<{blusas},{blusas},{oferta},{oferta}> → <{oferta}>	5.67	77.00	1.97

Nº	Regla (LHS → RHS)	Soporte (%)	Confianza (%)	Lift
4	<{pan- talones},{blusas},{blusas},{oferta}> → <{oferta}>	3.72	76.90	1.97
5	<{fal- das},{blusas},{blusas},{oferta}> → <{oferta}>	2.92	76.59	1.96
6	<{pan- talones},{blusas},{oferta},{oferta}> → <{oferta}>	3.67	76.33	1.96
7	<{oferta},{oferta},{oferta},{oferta}> → <{oferta}>	10.66	76.03	1.95
8	<{pan- talones},{pan- talones},{pan- talones},{oferta}> → <{oferta}>	6.31	75.85	1.94
9	<{blusas},{oferta},{oferta},{oferta}> → <{oferta}>	5.16	75.58	1.94
10	<{pan- talones},{oferta},{oferta},{oferta}> → <{oferta}>	5.76	75.54	1.94

Para esta parte del análisis, comparamos cómo se comportan los usuarios de Polonia de la República Checa al navegar por la categoría de blusas. Nuestro objetivo es entender sus hábitos para poder mejorar el sistema de recomendaciones. Los detalles exactos de los modelos y los porcentajes de las reglas que encontramos se pueden observar en la tabla adjunta.

7.4 Top 10 Reglas de Asociación: Polonia (Blusas)

rules	support	confidence	coverage	lift	count
{C12} => {C17}	0.030	0.377	0.079	2.911	252
{C17} => {C12}	0.030	0.229	0.130	2.911	252
{C17} => {C5}	0.028	0.219	0.130	1.455	241
{C7} => {C5}	0.028	0.295	0.095	1.954	238
{C1} => {C17}	0.024	0.256	0.094	1.975	204
{C12} => {C5}	0.022	0.283	0.079	1.877	189
{C14} => {C5}	0.022	0.215	0.102	1.425	186
{C57} => {C56}	0.022	0.343	0.063	3.769	183
{C56} => {C57}	0.022	0.237	0.091	3.769	183
{C11} => {C17}	0.022	0.287	0.075	2.216	183

Al mirar los datos de Polonia en la tabla, notamos que el comportamiento de búsqueda de la gente es bastante variado. Para poder encontrar patrones claros, tuvimos que pedirle al algoritmo que

sea un poco menos exigente. Los resultados nos demuestran que, si bien los usuarios polacos suelen comparar ciertas prendas, en general tienen una navegación dispersa y les gusta explorar muchas opciones distintas durante su sesión.

7.5 Top 10 Reglas de Asociación: República Checa (Blusas)

rules	support	confidence	coverage	lift	count
$\{C57\} \Rightarrow \{C56\}$	0.051	0.428	0.120	2.909	62
$\{C56\} \Rightarrow \{C57\}$	0.051	0.348	0.147	2.909	62
$\{C50\} \Rightarrow \{C49\}$	0.050	0.492	0.101	4.136	60
$\{C49\} \Rightarrow \{C50\}$	0.050	0.417	0.119	4.136	60
$\{C29\} \Rightarrow \{C40\}$	0.044	0.510	0.086	4.087	53
$\{C40\} \Rightarrow \{C29\}$	0.044	0.351	0.125	4.087	53
$\{C17\} \Rightarrow \{C5\}$	0.043	0.277	0.155	1.456	52

Por el contrario, en la República Checa nos encontramos con un público mucho más predecible. Como se ve en los números de la tabla, incluso siendo bastante más estrictos con los filtros del algoritmo, encontramos asociaciones muy fuertes y con un nivel de confianza alto. Esto nos indica que los consumidores checos tienen un recorrido de navegación directo y repiten constantemente la comparación entre pares de prendas muy puntuales, sin dar tantas vueltas por el catálogo.

Como conclusión principal que podemos sacar de todo esto es que no podemos usar la misma estrategia comercial para toda la página web. Como en la República Checa los clientes tienen hábitos tan marcados y directos, nos conviene poner un sistema de venta cruzada justo debajo de las fotos, ofreciendo exactamente esa otra blusa que sabemos que siempre miran. En cambio, en Polonia, la estrategia de recomendaciones tendría que mostrar un carrusel más abierto y variado, con varias opciones diferentes, para adaptarse a ese estilo de navegación más exploratorio que tienen.

8 Conclusiones:

A partir del análisis exhaustivo del comportamiento de navegación en el e-commerce, se han identificado patrones clave para la optimización de la plataforma. En primer lugar, los hábitos de exploración muestran una distribución fuertemente asimétrica hacia la derecha, donde aproximadamente el 75% de las sesiones registran entre 1 y 12 clics. Sin embargo, a medida que aumenta la cantidad de interacciones, los usuarios tienden a visualizar una mayor diversidad de productos, tal como se evidencia en los gráficos de dispersión sobre la exploración por sesión. Además, el análisis secuencial reveló que la navegación suele ser repetitiva dentro de una misma categoría y que la sección de “ofertas” funciona como el destino final del recorrido, con reglas secuenciales que alcanzan confianzas superiores al 75%.

En cuanto a la interfaz web y el impacto de los precios, se comprobó que la arquitectura espacial de la página condiciona directamente el tráfico. El mapa de calor sobre la distribución de clics según la posición en pantalla demuestra empíricamente que la atención se concentra en el cuadrante superior izquierdo, donde la categoría de pantalones alcanzó un pico de 10.855 interacciones, lo que justifica reservar este sector estratégico para el inventario de mayor prioridad. Paralelamente, los diagramas

de caja del análisis de precio indican que los productos con un valor superior al promedio logran un volumen de clics ligeramente mayor en comparación con los artículos más económicos.

Por otro lado, la aplicación de los algoritmos Apriori y ECLAT evidenció que los clientes no navegan por categorías aisladas, sino que buscan conjuntos o “outfits” compatibles. La tabla de itemsets a nivel general destaca la fuerte visualización conjunta de blusas y pantalones, combinación que posee un soporte del 24.82%. A nivel estético, la tabla de frecuencias de colores indica que los tonos neutros como el negro, azul y marrón dominan las búsquedas, descubriéndose además asociaciones cruzadas específicas de alto valor comercial, como la exploración conjunta de blusas blancas con pantalones azules.

Finalmente, la comparativa internacional demostró que no es viable aplicar una única estrategia comercial para toda la web. Al observar las reglas de asociación específicas por país, se nota que en Polonia (el mercado con mayor volumen de tráfico global) la navegación es muy variada y dispersa, lo que sugiere que su estrategia de recomendaciones debería basarse en carruseles abiertos y diversos. Por el contrario, en la República Checa los consumidores exhiben un comportamiento altamente predecible y directo, por lo que resulta más efectivo implementar un sistema de venta cruzada estricto directamente debajo de las fotos de los productos que ya están evaluando.